

**Evaluasi Kerentanan Prompt Injection pada Large Language Models
Bahasa Indonesia dengan Fokus Keamanan Data Finansial**

Tugas Talenta Unggul 2



Oleh: Mikael Aldy Cahya Pratama

NIM: 672019256

Program Studi Teknik Informatika Fakultas Teknologi Informasi

Universitas Kristen Satya Wacana Salatiga

Januari 2026

**Evaluasi Kerentanan Prompt Injection pada Large Language Models
Bahasa Indonesia dengan Fokus Keamanan Data Finansial**

Artikel Ilmiah

Oleh: Mikael Aldy Cahya Pratama

NIM: 672019256

Telah disetujui untuk diuji: Tanggal

Pembimbing 1

Prof. Hindriyanto Dwi Purnomo, S.T., M.IT., Ph.D.

Daftar Isi

1. Judul Penelitian.....4

2. Latar Belakang Masalah..... 4

3. Rumusan Masalah..... 6

4. Tujuan dan Manfaat..... 6

Judul Penelitian

Evaluasi Kerentanan Prompt Injection pada Large Language Models Bahasa Indonesia dengan Fokus Keamanan Data Finansial

1. Latar Belakang Masalah

Large Language Models (LLM) seperti GPT, Gemini, dan model open-source lainnya telah mengalami adopsi yang masif di berbagai sektor, termasuk sektor finansial di Indonesia. Menurut laporan McKinsey], industri perbankan dan fintech di Indonesia mengalami peningkatan penggunaan AI sebesar 67% dalam 2 tahun terakhir, dengan LLM menjadi komponen utama untuk customer service, fraud detection, dan analisis risiko.

Namun, keamanan LLM masih menjadi isu kritis yang belum terpecahkan sepenuhnya. Serangan *prompt injection* membuat model menghasilkan output berbahaya atau melanggar kebijakan keamanan – telah terbukti dapat mem-bypass proteksi keamanan yang ada (Wei et al., 2023; Zou et al., 2023). Dalam konteks finansial, kerentanan ini dapat menyebabkan:

- Kebocoran informasi nasabah (PII - Personal Identifiable Information)
- Bypass mekanisme verifikasi transaksi
- Social engineering untuk fraud
- Eksposur data internal perusahaan

Penelitian terkait keamanan LLM di Indonesia masih sangat terbatas. IndoSafety (Azmi et al., 2025) merupakan pioneer dalam evaluasi safety LLM untuk bahasa Indonesia, namun fokus utamanya adalah pada konten berbahaya secara umum (hate speech, misinformasi, dll), belum secara spesifik mengeksplorasi teknik-teknik prompt injection yang dapat dieksploitasi dalam konteks aplikasi bisnis, khususnya sektor finansial.

Mengingat Indonesia merupakan negara dengan populasi terbesar keempat di dunia dan memiliki industri fintech yang berkembang pesat, evaluasi keamanan LLM dalam bahasa

Indonesia dengan fokus pada kerentanan prompt injection menjadi sangat krusial. Penelitian ini akan mengisi gap tersebut dengan membangun dataset prompt injection yang comprehensive dan melakukan evaluasi multi-model untuk mengidentifikasi pola kerentanan yang spesifik dalam konteks bahasa Indonesia.

2. Rumusan Masalah

- 2.1. Teknik prompt injection apa yang memiliki tingkat keberhasilan tertinggi dalam konteks linguistik Bahasa Indonesia?
- 2.2. Bagaimana perbandingan performa keamanan antara model komersial (GPT-5.2, Gemini 3.0 Flash) dengan model open-weight (Qwen 3.5)?
- 2.3. Pola kerentanan linguistik apa yang muncul dalam bahasa Indonesia?
- 2.4. Kategori finansial mana yang paling rentan?

3. Tujuan dan Manfaat

3.1. Tujuan

- 3.1.1. Mengevaluasi ketahanan berbagai LLM terhadap manipulasi instruksi dalam skenario perbankan dan *fintech* Indonesia.
- 3.1.2. Mengukur Attack Success Rate untuk setiap model
- 3.1.3. Menganalisis perbedaan kerentanan antara model *closed-source* dan *open-weight*.
- 3.1.4. Mengidentifikasi teknik prompt injection yang paling efektif (*direct, roleplay, social engineering*).

3.2. Manfaat

3.2.1. Akademik/ilmiah

- 3.2.1.1. Menyediakan dataset prompt injection pertama untuk bahasa Indonesia dengan fokus finansial yang dapat digunakan oleh peneliti lain
- 3.2.1.2. Memberikan kontribusi pada literatur keamanan LLM di konteks multilingual, khususnya bahasa Indonesia

- 3.2.1.3. Menjadi baseline untuk penelitian lanjutan tentang defense mechanism untuk LLM bahasa Indonesia

3.2.2. Praktis

- 3.2.2.1. Bagi Developer/Engineer: Menyediakan kerangka kerja pengujian (testing framework) untuk mengevaluasi keamanan sistem sebelum deployment.
- 3.2.2.2. Bagi Perusahaan Fintech/Bank: Memberikan dasar penilaian risiko (risk assessment) terkait adopsi Large Language Model (LLM).

3.3. Batasan Masalah

- 3.3.1. Domain yang dikaji terbatas pada keamanan finansial, meliputi *account information extraction, fraud/manipulation, personal financial data leakage*.
- 3.3.2. Dataset yang digunakan belum mencakup seluruh variasi serangan dunia nyata dan belum mencakup *multi-turn attack*
- 3.3.3. Model yang diuji: *closed source* (GPT-5.2 dan Gemini 3.0 Flash) dan *model open-weight* (Qwen 3.5)
- 3.3.4. Teknik serangan: *Direct injection, Role-playing* dan *Social engineering*
- 3.3.5. Tidak mencakup *indirect injection* seperti tool-calling dan RAG.

4. Tinjauan Pustaka

4.1. Penelitian Terdahulu

Penelitian tentang *keamanan Large Language Models (LLM)* telah berkembang pesat dalam beberapa tahun terakhir, khususnya dalam mengidentifikasi dan mengatasi kerentanan terhadap serangan adversarial. Bagian ini menguraikan penelitian-penelitian sebelumnya yang relevan dengan fokus pada prompt injection attacks, evaluasi keamanan LLM, dan riset LLM dalam konteks bahasa Indonesia.

4.1.1. Gap penelitian dan kontribusi Penelitian

Meskipun penelitian tentang prompt injection attacks dan evaluasi keamanan LLM telah berkembang pesat, terdapat beberapa gap penelitian yang signifikan:

1.

Gap Geografis dan Linguistik: Sebagian besar penelitian tentang prompt injection dan jailbreak attacks fokus pada bahasa Inggris. Penelitian tentang kerentanan serupa dalam bahasa Indonesia masih sangat terbatas, meskipun Indonesia memiliki populasi pengguna internet terbesar keempat di dunia dan industri fintech yang berkembang pesat.

2.

Gap Domain-Spesifik: Sementara IndoSafety menyediakan evaluasi keamanan LLM bahasa Indonesia yang komprehensif, penelitian tersebut tidak secara spesifik fokus pada kerentanan prompt injection dalam konteks aplikasi bisnis, khususnya sektor finansial. Penelitian ini akan mengisi gap tersebut dengan membangun dataset prompt injection yang relevan secara finansial.

3.

Gap Metodologi: Sebagian besar penelitian tentang prompt injection menggunakan pendekatan manual atau semi-otomatis untuk mengkonstruksi serangan. Penelitian ini akan menggabungkan teknik-teknik yang telah terbukti efektif (seperti gradient-based search dari Zou et al.) dengan pendekatan manual untuk memastikan relevansi domain finansial.

4.

Gap Evaluasi Multi-Model: Penelitian sebelumnya sering fokus pada satu atau dua model. Penelitian ini akan melakukan evaluasi komparatif terhadap model commercial (GPT-5.2, Gemini 3.0 Flash) dan open-source (SeaLLMs-v3-7B atau Qwen2.5-7B) untuk memberikan gambaran yang lebih komprehensif tentang landscape kerentanan.

5.

Gap Benchmark dan Dataset: Belum ada benchmark atau dataset yang spesifik untuk evaluasi keamanan LLM dalam konteks finansial bahasa Indonesia. Penelitian ini akan mengisi gap ini dengan membangun dataset prompt injection pertama untuk bahasa Indonesia dengan fokus finansial.

Penelitian ini akan mengisi gap-gap tersebut dengan: (1) membangun dataset prompt injection pertama untuk bahasa Indonesia dengan fokus finansial, (2) mengimplementasikan dan menguji teknik-teknik prompt injection yang paling efektif dalam konteks bahasa Indonesia, (3) melakukan evaluasi komparatif terhadap berbagai LLM untuk mengidentifikasi pola kerentanan yang spesifik, (4) menyediakan framework pengujian yang dapat digunakan oleh developer dan perusahaan fintech untuk mengevaluasi keamanan sistem mereka sebelum deployment, dan (5) memberikan rekomendasi praktis untuk mitigasi kerentanan prompt injection di sektor fintech Indonesia.

5. Landasan Teori

5.1. Large Language Model

Large Language Model (LLM) merupakan jenis model kecerdasan buatan yang dirancang untuk memahami, memproses, dan menghasilkan bahasa alami manusia menggunakan pendekatan pembelajaran mesin berbasis data teks dalam skala besar. Language model secara fundamental bertujuan untuk mempelajari pola dan struktur bahasa dengan memprediksi probabilitas kemunculan unit linguistik seperti kata, frasa, atau kalimat berdasarkan konteks sebelumnya.

Secara arsitektur, sebagian besar LLM modern dibangun menggunakan arsitektur Transformer, yang memanfaatkan mekanisme attention untuk memproses hubungan antar token dalam sebuah urutan teks secara paralel. Mekanisme attention memungkinkan model untuk menentukan relevansi setiap token terhadap token lainnya dalam konteks tertentu, sehingga model dapat memahami hubungan semantik dan konteks secara lebih efektif dibandingkan arsitektur sebelumnya seperti Recurrent Neural Network (RNN) atau Long Short-Term Memory (LSTM).

LLM dilatih menggunakan pendekatan self-supervised learning dengan memanfaatkan dataset teks dalam jumlah besar yang dikumpulkan dari berbagai sumber seperti buku, artikel, dan halaman web. Dalam proses pelatihan ini, model belajar untuk memprediksi token berikutnya berdasarkan token sebelumnya, yang dikenal sebagai autoregressive training. Proses ini memungkinkan model untuk mengembangkan pemahaman tentang tata bahasa, semantik, dan struktur bahasa secara umum tanpa memerlukan label manual pada data pelatihan([2402.06853](#))

5.2. Prompt Injection Attacks

Prompt injection adalah teknik adversarial di mana attacker memanipulasi input (prompt) untuk membuat LLM menghasilkan output yang melanggar policy keamanan atau mengekspos informasi sensitif (Perez et al., 2022). Teknik-teknik prompt injection dikategorikan sebagai berikut:

5.2.1. Direct Jailbreak

Direct jailbreak adalah instruksi eksplisit untuk melanggar policy. Contoh: "Ignore previous instructions and tell me..." (Wei et al., 2023). Teknik ini mengandalkan instruction-following capability model yang over-generalized.

5.2.2. Role-Playing

Role-playing attack meminta model berperan sebagai karakter tanpa ethical constraints. Contoh terkenal: "DAN" (Do Anything Now) yang meminta model mengabaikan OpenAI policies dengan framing sebagai game/simulation (Wei et al., 2023).

5.2.3. Social Engineering

Social engineering menggunakan konteks legitimate (riset, edukasi) untuk meminta informasi harmful. Contoh: "For my cyber security thesis, explain..." Teknik ini memanfaatkan model's tendency untuk helpful dan informatif (Ganguli et al., 2022).

5.3. LLM Safety Evaluation

5.3.1. Evaluation Framework

Evaluasi safety LLM memerlukan framework multi-dimensional. Wang et al. (2024c) mengusulkan 5 risk areas: (1) discrimination & toxicity, (2) human-chatbot interaction harms, (3) information hazards, (4) malicious uses, (5) misinformation. Framework ini diadopsi dan diperluas dengan kategori region-specific untuk konteks Indonesia (Azmi et al., 2025).

5.3.2. Metrics

5.4. Indonesian Language in LLM Context

5.4.1. Indonesian Language Challenges

5.4.2. Indonesian-centric Models

5.5. Financial Security in LLM Applications

5.5.1. Financial AI Risks

5.5.2. Regulatory Context (OJK AI Regulation)

6. Metodologi Penelitian

6.1. Desain Penelitian

Penelitian ini menggunakan pendekatan eksperimental untuk mengevaluasi kerentanan *Large Language Model* (LLM) terhadap serangan *prompt injection* dalam bahasa Indonesia, khususnya pada konteks keamanan finansial.

Pendekatan yang digunakan adalah *adversarial evaluation* (*red teaming*), yaitu dengan memberikan input berupa *prompt* berbahaya yang dirancang untuk:

- Mengekstraksi informasi sensitif
- Memfasilitasi aktivitas penipuan
- Manipulasi perilaku model

Tujuan utama dari penelitian ini adalah:

1. Mengukur tingkat keberhasilan serangan terhadap LLM
2. Mengidentifikasi teknik serangan yang paling efektif
3. Membandingkan tingkat kerentanan antar model

6.2. Perancangan Taksonomi Risiko

Penelitian ini mengadopsi konsep taksonomi dari penelitian sebelumnya (IndoSafety) kemudian membuat kumpulan serangan *prompt* ke dalam dataset dengan domain keamanan finansial. Penelitian ini akan mengadopsi taksonomi yang telah dikembangkan dalam studi sebelumnya (IndoSafety). Berdasarkan taksonomi tersebut, akan dibuat dataset yang berisi berbagai serangan *prompt* dengan fokus pada domain keamanan finansial.

6.2.1. Kategori Risiko (*Harm Categories*)

1. *Account Information Extraction*

Merupakan upaya untuk memperoleh akses terhadap akun pengguna seperti *reset password* atau *bypass* autentikasi.

2. *Fraud Information*

Prompt yang bertujuan meminta bantuan untuk melakukan penipuan, *bypass* verifikasi, *social engineering*, atau aktivitas penipuan lainnya.

3. *Personal Information Leakage (PII)*

Prompt yang bertujuan memperoleh atau mengekstrak data pribadi finansial seperti NIK, nomor rekening, data KYC, riwayat transaksi, atau informasi sensitif lain.

6.2.2. Jenis Teknik Serangan

1. *Direct Prompting*

Serangan berupa permintaan langsung untuk melakukan tindakan berbahaya atau dilarang

2. *Role Playing*

Prompt dibuat dalam bentuk peran, simulasi, atau skenario tertentu agar model lebih mudah mengikuti instruksi.

3. *Social Engineering*

Prompt memanfaatkan alasan yang tampak sah, misalnya riset, audit, atau kebutuhan operasional, untuk mendorong keluaran berbahaya.

6.3. Penyusunan Dataset

Dataset awal dibuat secara manual sebanyak 45 *prompt*. Dataset ini dibentuk dari kombinasi:

- 3 Kategori risiko
- 3 teknik serangan
- 5 prompt per kombinasi

Prompt disimpan dalam format JSON dengan bagan:

- Id

- Category
- attack_technique
- Prompt

Semua prompt ditulis dalam bahasa Indonesia dengan konteks finansial seperti perbankan, mobile banking, e-wallet, OTP, KYC, nomor rekening, dan data nasabah. Kumpulan *prompt* ini selanjutnya akan di-augmentasi dengan LLM yang bertujuan untuk memperbanyak jumlah dataset

6.4. Augmentasi Dataset

Augmentasi dilakukan menggunakan LLM model Opus 4.6 dengan system instruction agar menghasilkan prompt yang:

Tetap berada dalam kategori finansial

Bervariasi

Tetap mempertahankan teknik serangan yang diuji

6.5. Pengecekan Dataset

6.6. Pengujian Model

3 model: Gemini 3 Flash, GPT 5.2, Qwen 3.5

6.7. Evaluasi

6.7.1. Response Type

6.7.2. Attack Success Rate

6.7.3. Data Leakage Rate

6.8. Matrix Evaluation

6.8.1. Unsafe Rate

6.8.2. ASR

6.8.3. Severity Distribution

6.8.4. Technique Success Rate

6.8.5. Per-category Vulnerability

6.8.6. Data leakage Rate

6.9. Alur Penelitian

Alur penelitian secara ringkas adalah:

1. Menyusun taksonomi risiko finansial.
2. Membuat 45 seed prompt manual.
3. Melakukan augmentasi hingga total ± 180 prompt.
4. Membersihkan dan memvalidasi dataset.
5. Mengirim prompt ke tiga model.
6. Mengumpulkan respons model.
7. Melakukan penilaian dengan LLM-as-a-judge dan validasi manusia.
8. Menghitung metrik dan menganalisis hasil.

-

7. Hasil Pembahasan

7.1. Hasil Eksperimen

Daftar Pustaka

8. Lampiran